Reactive Diffusion Policy:
Slow-Fast Visual-Tactile Policy Learning for Contact-Rich Manipulation

Han Xue[1*] Jieji Ren[1*] Wendi Chen[1*]
Gu Zhang[234†] Yuan Fang[1†] Guoying Gu[1] Huazhe Xu[234‡] Cewu Lu[15‡]
[1]Shanghai Jiao Tong University [2]Tsinghua University, IIIS [3]Shanghai Qi Zhi Institute
[4]Shanghai AI Laboratory [5]Shanghai Innovation Institute
*Equal contribution †Equal contribution ‡Equal advising

reactive-diffusion-policy.github.io

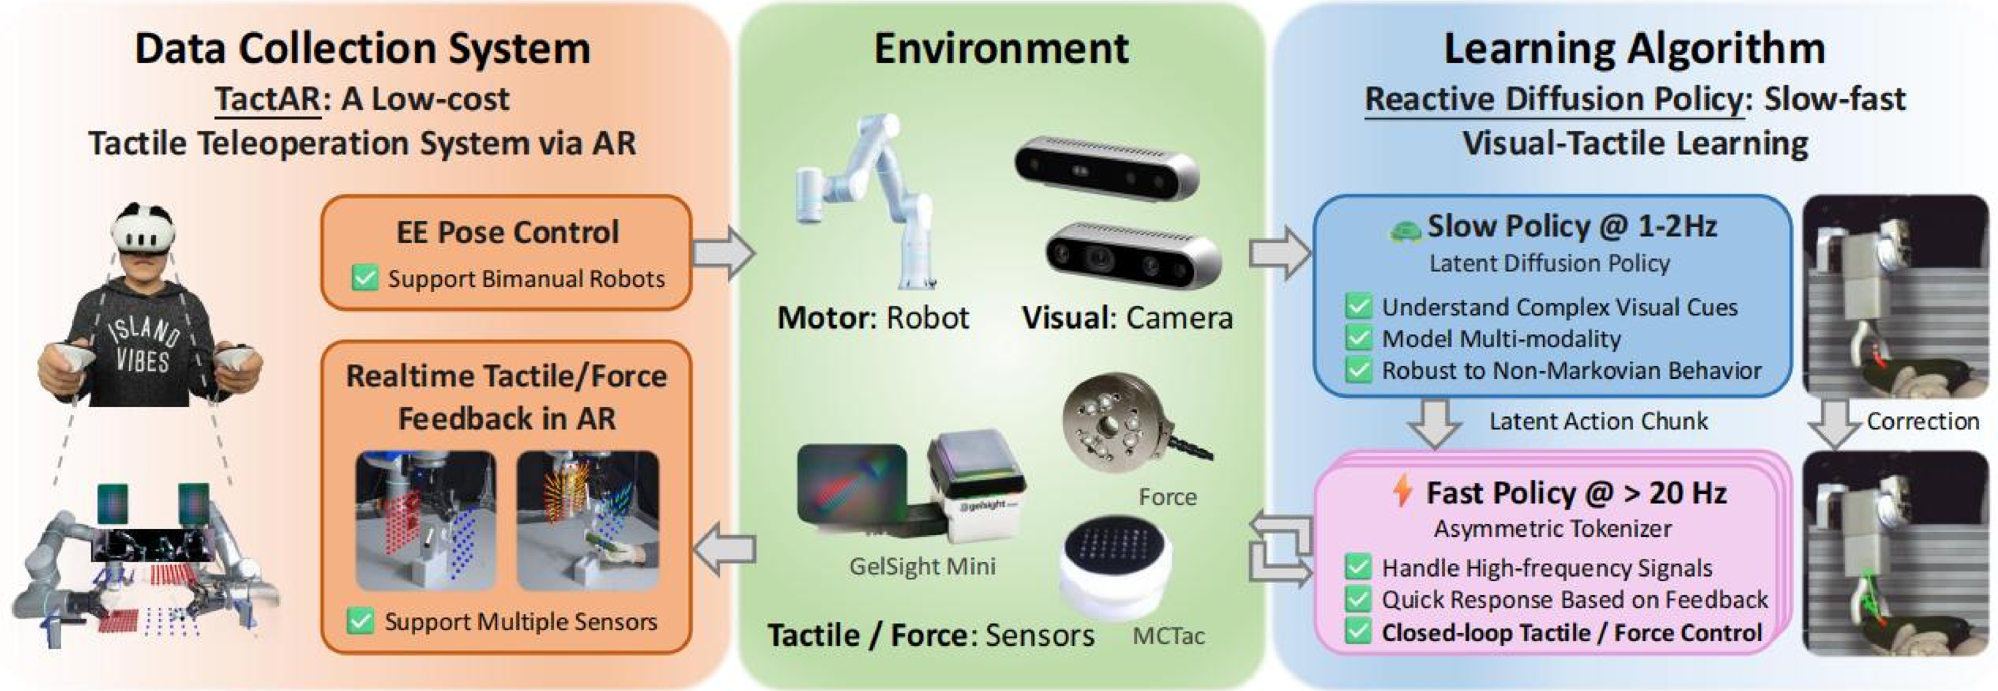

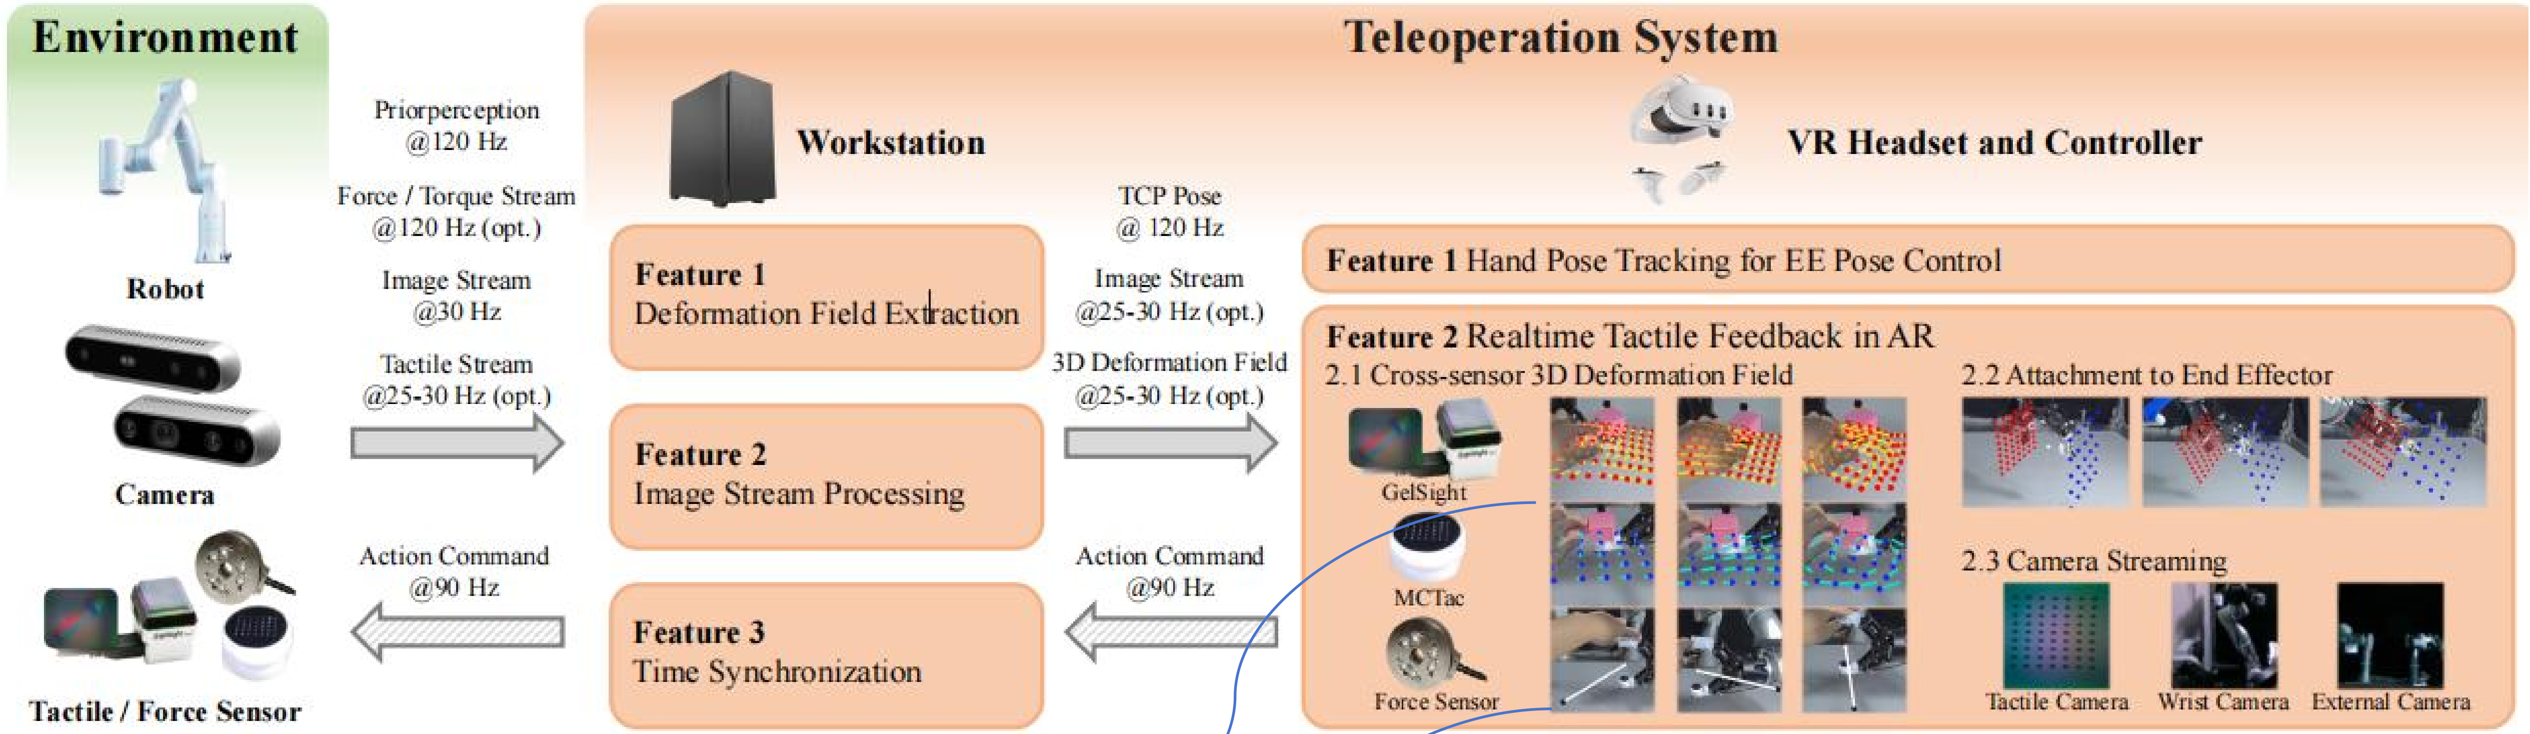

用 OpenCV 提取每个 marker 的位置 D_t

计算初始帧 D_0 到当前帧 D_t 的光流：

$$F_t = [dx, dy] = \mathrm{Flow}(D_0, D_t)$$

再给每个 marker 加上一个法向位移 o_z，形成 3D 形变场：

$$V_t = [dx, dy, o_z]$$

直接把 3D 力 / 力矩 $[f_x, f_y, f_z]$ 当成 3D 向量：

$$V_t = [f_x, f_y, f_z]$$

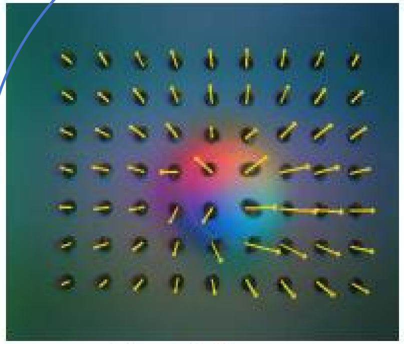

Normal Force

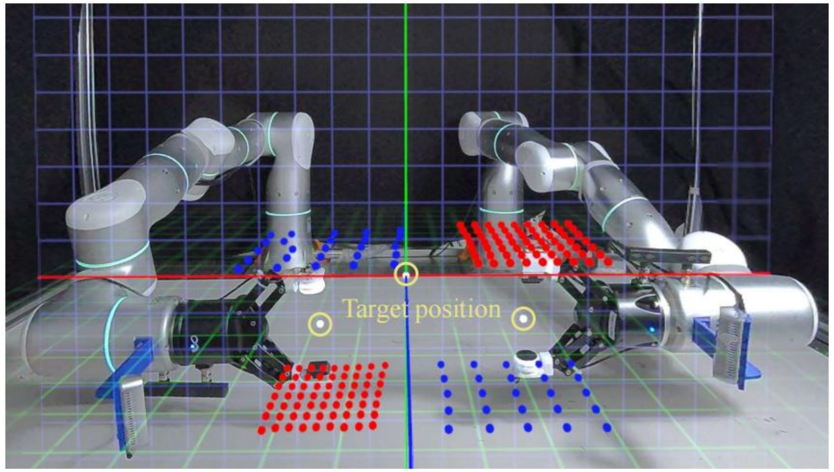

After calibration

最终转换成AR 世界坐标系下的 3D 向量场

$$V_{\mathrm{AR}} = {}^{\mathrm{AR}}T_{\mathrm{Robot}} \cdot {}^{\mathrm{Robot}}T_{\mathrm{TCP}} \cdot {}^{\mathrm{TCP}}T_{\mathrm{Sensor}} \cdot V_{\mathrm{sensor}}$$

RDP 算法

1.Tactile / Force Representation

力传感器：直接把 3D 力 + 3D 力矩拼进观测向量

视触觉传感器：

每帧图像中，每个 marker 都会产生一个二维的切向位移 [dx,dy]，一帧触觉数据可以表示为一个高维向量 $F_t \in \mathbb{R}^{2n}$

GelSight Mini 有n=7×9=63个 marker，每帧触觉数据是一个 126 维向量。

高维数据冗余，不同维度之间高度相关→PCA（主成分分析）

构造触觉数据矩阵、求协方差、做特征分解，选取前 d 个最大特征值对应的特征向量构成投影矩阵 T_{proj}

$$D_{\text{tactile}} = \{F_1, F_2, \ldots, F_m\}, \quad F_t \in \mathbb{R}^{2n}$$

$$F_{\text{concat}} = \begin{bmatrix} F_1^T \\ F_2^T \\ \vdots \\ F_m^T \end{bmatrix} \quad F_{\text{concat}} \in \mathbb{R}^{m \times 2n}$$

$$\tilde{F} = F_{\text{concat}} - \mu, \quad \mu = \frac{1}{m}\sum_{t=1}^{m} F_t$$

$$C = \frac{1}{m-1}\tilde{F}^T \tilde{F}$$

描述各 marker 位移维度之间的相关性

$$C = U \Lambda U^T \qquad T_{\text{proj}} = U_{[:,\,1:d]}$$

U：特征向量矩阵（每列是一个主方向）

Λ：特征值（表示方差大小）

对于新的触觉帧，先做去中心化，再乘以投影矩阵，

$$\tilde{F}_{t'} = F_{t'} - \mu \qquad f_{t'}^{\text{PCA}} = T_{\text{proj}}^T \tilde{F}_{t'} \qquad f_{t'}^{\text{PCA}} \in \mathbb{R}^d$$

得到d 维触觉 embedding（d = 15 ）

15维已经能覆盖 > 95% 的触觉方差信息

RDP 算法

慢策略:低频上预测latent action chunk,　　　“大脑/计划层”

2.Slow-Fast Policy Learning

快策略:更高频率读取最新的触觉/力反馈,
对这段 latent 做帧级别的闭环细调,　　“反射/小脑”

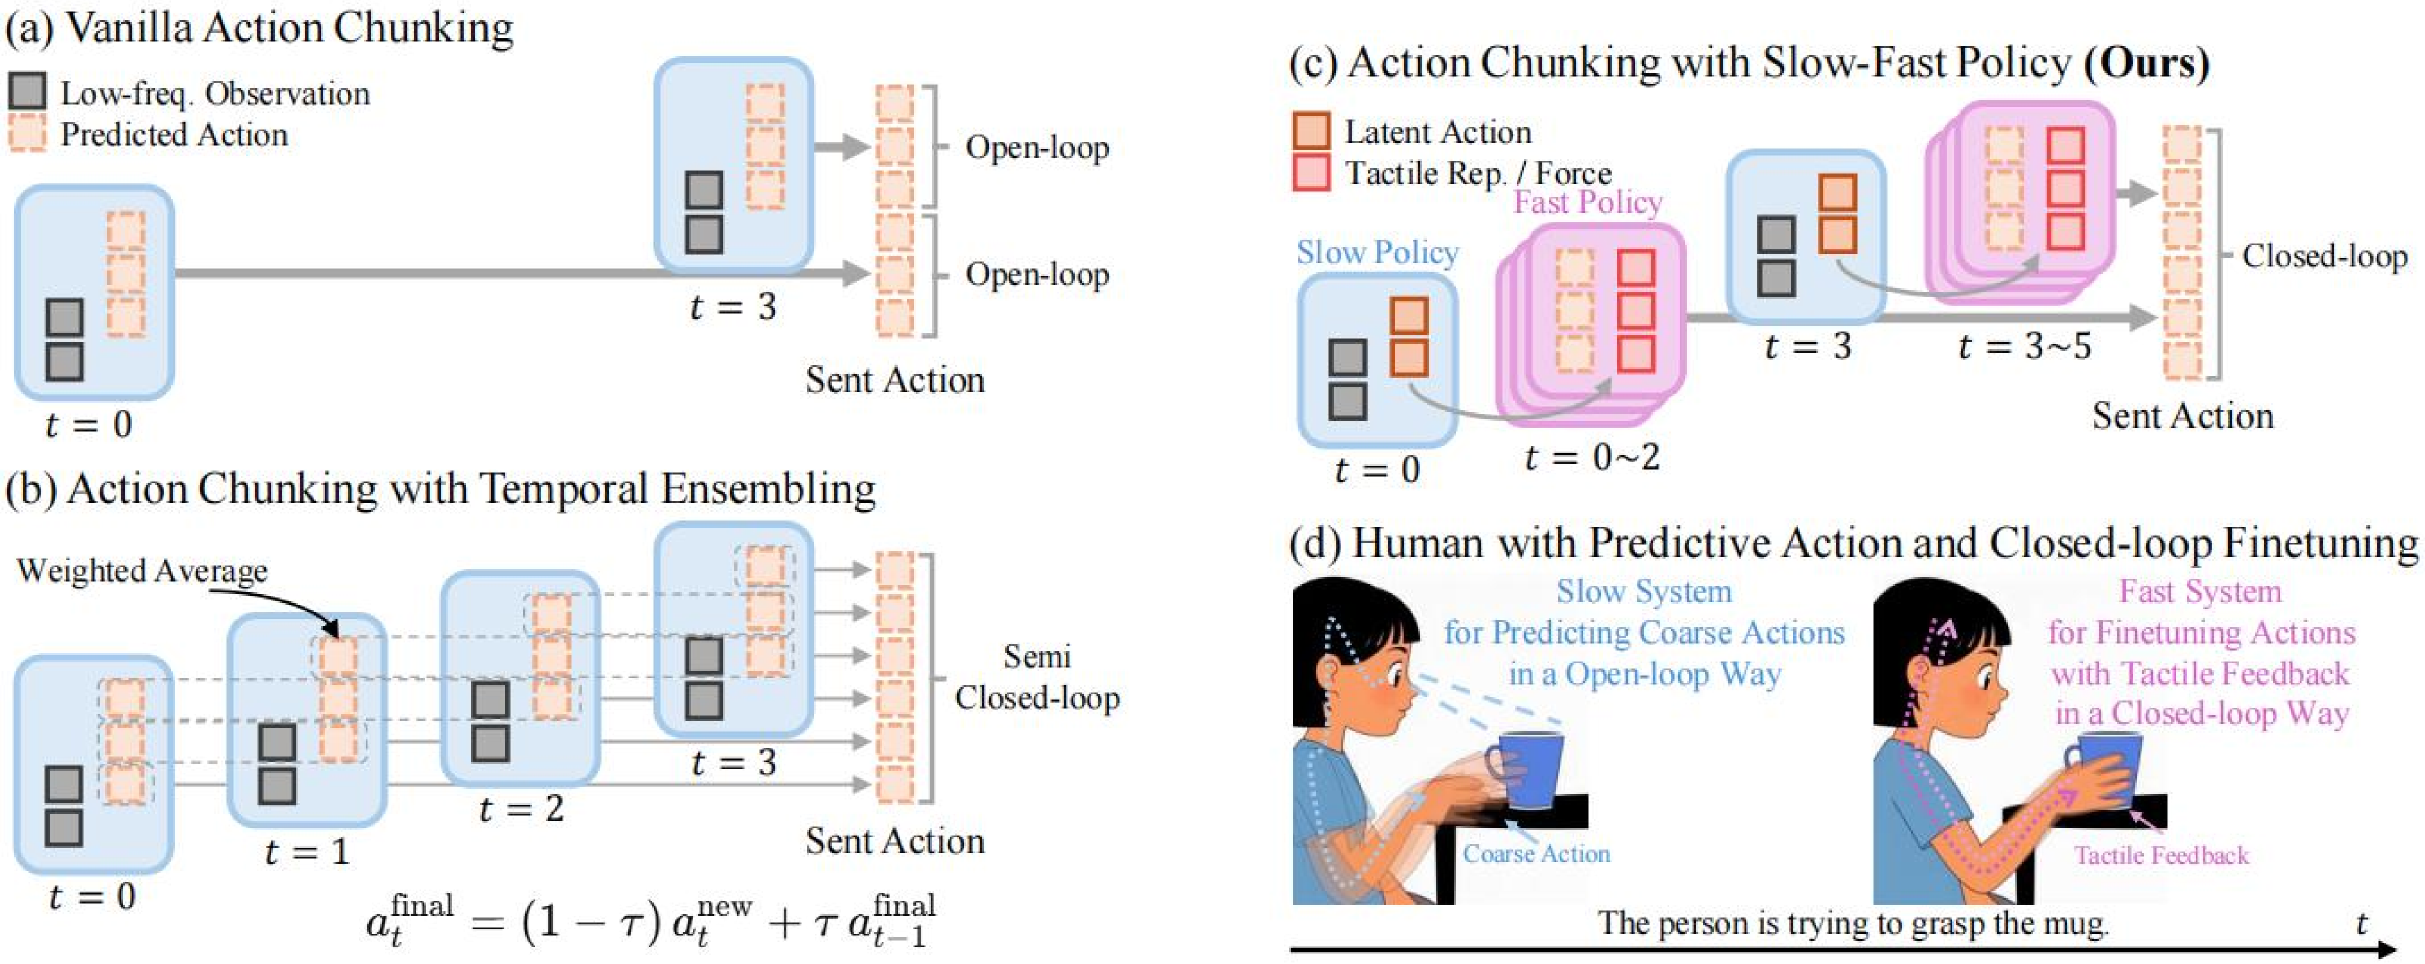

多个时间步对同一时刻的预测做加权平均

RDP 算法

2.Slow-Fast Policy Learning

(a) Training Pipeline of Reactive Diffusion Policy

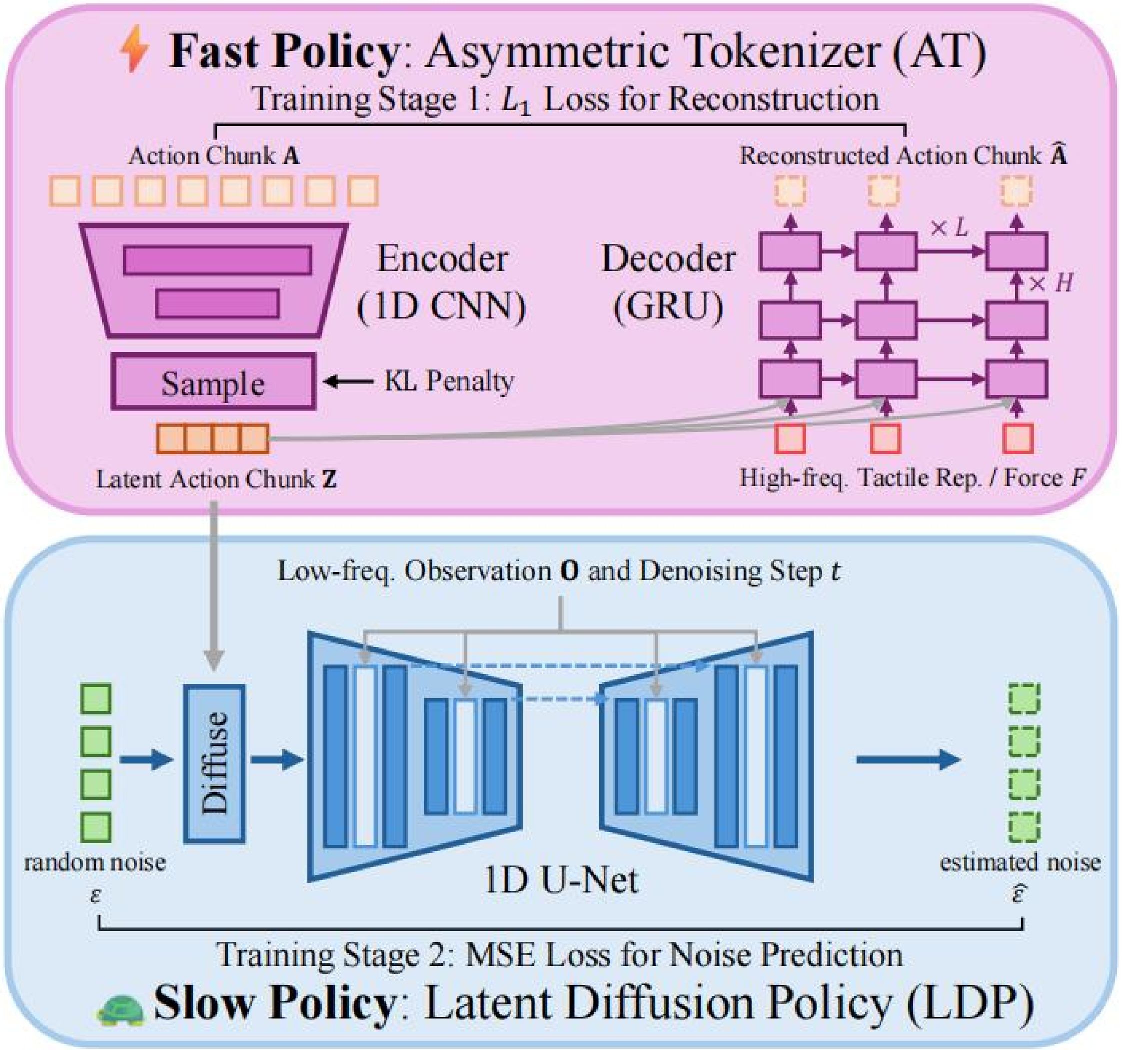

Stage 1：把 action chunk 编成 latent 表示（AT 的 encoder），并学一个带触觉输入的 decoder 来重建动作，快策略

$A \in \mathbb{R}^{T \times D} \qquad h_t^{(1)} = \mathrm{Conv1D}(A_{t-k:t+k})$

$Z = E(A) \in \mathbb{R}^{t \times d}, \quad t < T$ 只包含高层策略 / 轨迹结构

$\hat{A} = D(\mathrm{concat}[Z, F^{\mathrm{reduced}}]) \qquad F^{\mathrm{reduced}} \in \mathbb{R}^{T \times 15}$

训练目标：$\mathcal{L}_{\mathrm{AT}} = \mathbb{E}_{(A, F^{\mathrm{reduced}}) \sim \mathcal{D}_{\mathrm{policy}}} \left[\|A - \hat{A}\|_1 + \lambda_{\mathrm{KL}}\, \mathrm{KL} \right]$

$KL(q(Z|A) \,\|\, \mathcal{N}(0, I))$

高频闭环推理：AT decoder 每一帧都会拿最新的触觉 / 力 embedding + latent，输出下一步动作，跑到 >300 Hz

Stage 2：在 latent 空间上训练 Diffusion Policy（LDP），预测 latent action chunk，慢策略

$Z_0 = E(A_0)$ 在 latent 上加噪声：$Z_k = Z_0 + \epsilon_k$

给定观测，学习一个噪声预测器，训练目标：

$$\mathcal{L}_{\mathrm{LDP}} = \mathbb{E}_{(O, A_0), k, \epsilon_k} \left\| \epsilon_k - \epsilon_\theta(O, Z_0 + \epsilon_k, k) \right\|_2^2$$

RDP 算法

2.Slow-Fast Policy Learning

(b) Inference Pipeline of Slow-Fast Policy

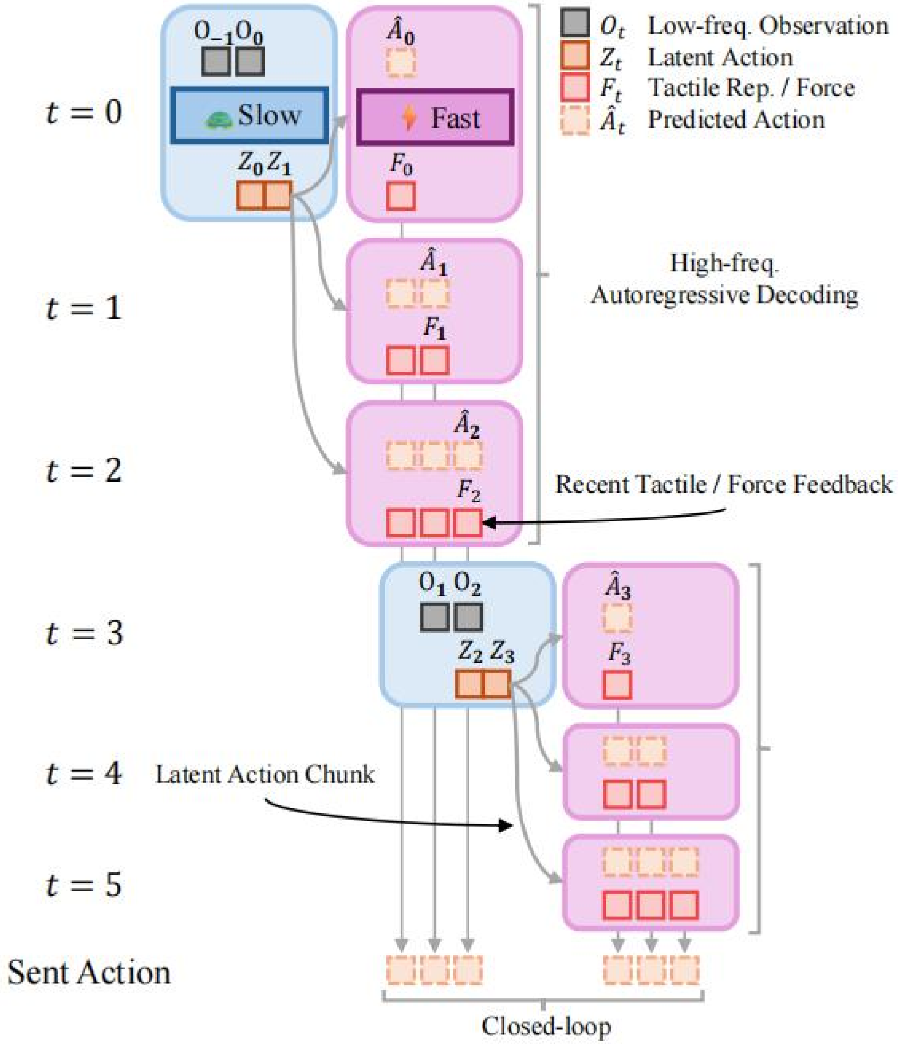

慢策略（LDP）低频（1–2 Hz）预测一个 latent action chunk Z；

快策略（AT decoder）高频（24 Hz）读取当前触觉 / 力 embedding，在 latent chunk 基础上逐步生成每一帧动作，并闭环调整。

LDP ~100ms， AT <1ms（在 4090 上）

实验

Q1: 只加触觉信息能帮多少?
Q2: RDP 的能力
Q3: 传感器泛化
Q4: 即时扰动响应
Q5: ablation：为什么不能缩短 chunk?
用 temporal ensemble?
Q6 & Q7: TactAR 提升数据质量 →
进一步提升策略性能

Diffusion Policy（纯视觉）

Diffusion Policy + 触觉图像

Diffusion Policy + 触觉 embedding

RDP（tactile embedding）

RDP（force）

局限性与未来工作

- TactAR 虽然能在 AR 中展现触觉 / 力，但远不如直接用人手操作直观：未来可以从进一步降低延迟等方向优化；目前系统主要针对两指夹持：扩展到多指灵巧手 + 高维触觉是一个重要方向
- Fast policy 现阶段只处理高频触觉 / 力：之后可以考虑高频视觉（如高速相机）也接入 fast 通路；当前 RDP 只做单任务：未来可以把 RDP 嵌进 VLA（vision-language-action）模型，比如把原来的 tokenizer 换成类似 asymmetric tokenizer，使大模型策略也具备触觉驱动的 reactive 能力